



Examen Final - Parte 2

Anthony Enrique Huertas Quispe Cod:20173728
Prof: Cristian Bayes

Pregunta 3

Una variable aleatoria Y tiene distribución *Cauchy* si su función de densidad es dada por

$$f_Y(y) = \frac{1}{\pi\sigma} \left(1 + \left(\frac{y - \mu}{\sigma} \right)^2 \right)^{-1} \quad (1)$$

donde $\mu \in \mathbb{R}$ y $\sigma^2 > 0$. Consideremos la siguiente notación $Y \sim \text{Cauchy}(\mu, \sigma^2)$ para representar una variable aleatoria que siga esta distribución. Esta distribución tiene la siguiente propiedad: Sean Y y W dos variables aleatorias tales que

$$Y|W \sim N\left(\mu, \frac{\sigma^2}{W}\right) \quad (2)$$

$$W \sim \text{Gamma}\left(\frac{1}{2}, \frac{1}{2}\right) \quad (3)$$

entonces $Y \sim \text{Cauchy}(\mu, \sigma^2)$.

Asuma que Y_1, Y_2, \dots, Y_n , condicional a μ y σ^2 , son variables aleatorias independientes con distribución *Cauchy*(μ, σ^2).

- a) A partir de la propiedad encuentre la distribución de W_i condicional a Y_i .

Solución. Usando el Teorema de Bayes tenemos que:

$$\begin{aligned} f(w_i|y_i) &\propto f(y_i|w_i)f(w_i) \\ &\propto \frac{w_i^{1/2}}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{y_i - \mu}{\sigma}\right)^2 w_i\right\} \frac{1/2^{1/2}}{\Gamma(1/2)} w_i^{1/2-1} \exp\{-w_i/2\} \\ &\propto \exp\left\{-\left(\frac{1}{2} + \frac{1}{2}\left(\frac{y_i - \mu}{\sigma}\right)^2\right) w_i\right\} \end{aligned} \quad (4)$$

Por tanto,

$$W_i|Y_i \sim \text{Exp}\left(\frac{1}{2} + \frac{1}{2}\left(\frac{y_i - \mu}{\sigma}\right)^2\right) \quad (5)$$

□

- b) Implemente el algoritmo EM para el conjunto de datos *darwin* de la librería *LearnBayes*.

Solución. Primero determinemos la función verosimilitud

$$\begin{aligned} \mathcal{L}(\mu, \sigma^2 | W, y) &= \prod_{i=1}^n f(y_i|w_i)f(w_i) \\ &= \prod_{i=1}^n \frac{w_i^{1/2}}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{1}{2}\left(\frac{y_i - \mu}{\sigma}\right)^2 w_i\right\} \frac{1/2^{1/2}}{\Gamma(1/2)} w_i^{1/2-1} \exp\{-w_i/2\} \\ &\propto \frac{1}{(\sigma^2)^{n/2}} \exp\left\{-\frac{1}{2}\sum_{i=1}^n \left(\frac{y_i - \mu}{\sigma}\right)^2 w_i\right\} \end{aligned} \quad (6)$$

luego la función log-verosimilitud vendría dada por

$$\ell(\mu, \sigma^2 \mid W, y) \propto -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 w_i \quad (7)$$

Por (5) tenemos además que

$$E_{\mathbf{W} \mid \mathbf{Y}=\mathbf{y}, \mu=\mu^{(j)}, \sigma^2=\sigma^{2(j)}}[w_i] = \left(\frac{1}{2} + \frac{1}{2\sigma^{2(j)}} (y_i - \mu^{(j)})^2 \right)^{-1} \quad (8)$$

Por consiguiente el algoritmo EM, vendría determinado por los siguientes pasos:

- **Paso E:** Tomando $\theta = (\mu, \sigma^2)$.

$$\begin{aligned} Q(\theta, \theta^{(j)}) &= E_{\mathbf{W} \mid \mathbf{Y}=\mathbf{y}, \mu=\mu^{(j)}, \sigma^2=\sigma^{2(j)}}[\ell(\mu, \sigma^2 \mid W, y)] \\ &= E_{\mathbf{W} \mid \mathbf{Y}=\mathbf{y}, \mu=\mu^{(j)}, \sigma^2=\sigma^{2(j)}} \left[-\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 w_i \right] \\ &= -\frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2 E_{\mathbf{W} \mid \mathbf{Y}=\mathbf{y}, \mu=\mu^{(j)}, \sigma^2=\sigma^{2(j)}}[w_i] \\ &= -\frac{n}{2} \log(\sigma^2) - \frac{1}{\sigma^2} \sum_{i=1}^n \frac{(y_i - \mu)^2}{1 + \frac{1}{\sigma^{2(j)}} (y_i - \mu^{(j)})^2} \end{aligned} \quad (9)$$

- **Paso M:**

$$\frac{\partial Q}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n \frac{2(y_i - \mu)}{1 + \frac{1}{\sigma^{2(j)}} (y_i - \mu^{(j)})^2} = 0 \quad (10)$$

$$\frac{\partial Q}{\partial (\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{\sigma^4} \sum_{i=1}^n \frac{(y_i - \mu)^2}{1 + \frac{1}{\sigma^{2(j)}} (y_i - \mu^{(j)})^2} = 0 \quad (11)$$

Despejando μ y σ^2 :

$$\mu^{(j+1)} = \frac{\sum_{i=1}^n y_i \hat{w}_i^{(j)}}{\sum_{i=1}^n \hat{w}_i^{(j)}} \quad \wedge \quad \sigma^{2(j+1)} = 2 \sum_{i=1}^n \frac{(y_i - \mu^{(j+1)})^2 \hat{w}_i^{(j)}}{n} \quad (12)$$

$$\text{donde } \hat{w}_i^{(j)} = \left(1 + \frac{1}{\sigma^{2(j)}} (y_i - \mu^{(j)})^2 \right)^{-1}.$$

Listing 1: Algoritmo EM - Darwin (LearnBayes)

```

1 library(LearnBayes)
2
3 y=data.frame(darwin)[,1]
4
5 # Algoritmo EM
6
7 res=matrix(c(mean(y),var(y)),1,2) #Iniciando valores
8
9 cont=0
10 h=0
11 while(cont==0){
12     h=h+1
13     theta.old=res[h,] #theta=(mu, sigma^2)
14     w=(1+((y-theta.old[1])^2)/theta.old[2])^(-1)
15     theta.new=c(0,0)
16     theta.new[1]=sum(y*w)/sum(w)
17     theta.new[2]=mean((y-theta.new[1])^2*w*2)
18     res=rbind(res,theta.new)
19     if(sum((theta.new-theta.old)^2)<1e-20){cont<-1}
20 }
21 res

```

Resultado:

	μ	σ^2
	20.93333	1424.6381
theta.new	24.93518	778.5697
theta.new	25.89387	542.9205
	\vdots	\vdots
theta.new	24.97054	246.6743
theta.new	24.97054	246.6743

Habiéndose estimado los parámetros μ y σ^2 , mediante el algoritmo EM, se infiere la distribución de Y como sigue

$$Y \sim \text{Cauchy}(24.97054, 246.6743) \quad (13)$$

□

- c) Mediante bootstrap encuentre un intervalo de confianza del 95 % para los parámetros del modelo.

Solución. Haremos uso de la librería `boot` y de las funciones `boot` y `boot.ci` (para intervalos de confianza).

Listing 2: Intervalo de Confianza para la Media - Darwin (LearnBayes)

```

1 library(LearnBayes)
2 library(boot)
3
4 y=data.frame(darwin)[,1]
5
6 media=function(data,index){
7     mean(data[index])
8 }
9 res=boot(y,media,1000) # Función Bootstrap
10
11 # Intervalo de Confianza Bootstrap
12 boot.ci(res,conf=0.95,type="all")

```

Resultado:

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 1000 bootstrap replicates
Intervals :
Level Normal Basic Percentile BCa
95 % (2.56, 39.05) (3.20, 39.93) (1.94, 38.67) (-1.77, 36.55)

Listing 3: Intervalo de Confianza para la Varianza - Darwin (LearnBayes)

```

1 library(LearnBayes)
2 library(boot)
3
4 y=data.frame(darwin)[,1]
5
6 Var=function(data,index){
7     var(data[index])
8 }
9 res2=boot(y,Var,1000) # Función Bootstrap
10
11 # Intervalo de Confianza Bootstrap
12 boot.ci(res2,conf=0.95,type="all")

```

Resultado:

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 1000 bootstrap replicates
Intervals :
Level Normal Basic Percentile BCa
95 % (368, 2622) (350, 2521) (328, 2500) (506, 3115)

□

d) Considere que la distribución *a priori* de μ y σ^2 es dada por

$$p(\mu, \sigma^2) \propto \frac{1}{\sigma^2} \quad (14)$$

Halle la distribución *a posteriori* aumentada de $\theta = (\mu, \sigma^2)^T$ y $W = (w_1, \dots, w_n)^T$ y encuentre las distribuciones condicionales completas de μ, σ^2 y w_i .

Solución. En primera instancia la distribución *a posteriori* aumentada cumple lo siguiente

$$\begin{aligned} p(\mu, \sigma^2, W | y) &\propto p(W, y | \mu, \sigma^2) p(\mu, \sigma^2) \\ &\propto \frac{1}{(\sigma^2)^{n/2}} \exp \left\{ -\frac{1}{2} \left(\sum_{i=1}^n \left(\frac{y_i - \mu}{\sigma} \right)^2 w_i + \sum_{i=1}^n w_i \right) \right\} \frac{1}{\sigma^2} \\ &\propto \frac{1}{(\sigma^2)^{n/2+1}} \exp \left\{ -\frac{1}{2} \left(\sum_{i=1}^n \left(\frac{y_i - \mu}{\sigma} \right)^2 w_i + \sum_{i=1}^n w_i \right) \right\} \end{aligned} \quad (15)$$

Determinemos las siguientes distribuciones condicionales completas

- De μ :

$$\begin{aligned} p(\mu | y, \sigma^2, W) &\propto \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{y_i - \mu}{\sigma} \right)^2 w_i \right\} \\ &\propto \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i^2 w_i + \mu^2 w_i - 2\mu y_i w_i) \right\} \\ &\propto \exp \left\{ -\frac{1}{2\sigma^2} \left(\mu^2 \sum_{i=1}^n w_i - 2\mu \sum_{i=1}^n y_i w_i \right) \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n w_i}{\sigma^2} \left(\mu^2 - 2\mu \frac{\sum_{i=1}^n y_i w_i}{\sum_{i=1}^n w_i} \right) \right\} \\ &\propto \exp \left\{ -\frac{1}{2} \frac{\sum_{i=1}^n w_i}{\sigma^2} \left(\mu - \frac{\sum_{i=1}^n y_i w_i}{\sum_{i=1}^n w_i} \right)^2 \right\} \end{aligned}$$

Por tanto,

$$\mu | y, \sigma^2, W \sim N \left(\frac{\sum_{i=1}^n y_i w_i}{\sum_{i=1}^n w_i}, \frac{\sigma^2}{\sum_{i=1}^n w_i} \right) \quad (16)$$

- De σ^2 :

$$p(\sigma^2 | y, \mu, W) \propto \left(\frac{1}{\sigma^2} \right)^{n/2+1} \exp \left\{ -\left(\frac{1}{\sigma^2} \right) \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2 w_i \right\}$$

Por tanto,

$$\frac{1}{\sigma^2} | y, \mu, W \sim \text{Gamma} \left(\frac{n}{2}, \frac{1}{2} \sum_{i=1}^n (y_i - \mu)^2 w_i \right) \quad (17)$$

- De w_i :

$$p(w_i | y, \sigma^2, w_1, \dots, w_{i-1}, w_{i+1}, w_n) \propto \exp \left\{ -\left(\frac{1}{2} \left(\frac{y_i - \mu}{\sigma} \right)^2 + \frac{1}{2} \right) w_i \right\}$$

Por tanto,

$$w_i | y, \mu, \sigma^2, w_1, \dots, w_{i-1}, w_{i+1}, \dots, w_n \sim \text{Exp} \left(\frac{1}{2} + \frac{1}{2\sigma^2} (y_i - \mu)^2 \right) \quad (18)$$

□

- e) Implemente el algoritmo de Gibbs en R para el conjunto de datos `darwin` de la librería `LearnBayes`. Realice 10,000 simulaciones de la distribución a posteriori, presente gráficos de la cadena, autocorrelación, histogramas y estadísticas resumen. Comente sus resultados.

Solución. El algoritmo de Gibbs esta dado por:

$$\mu^{(j+1)} | y, \sigma^{2(j)}, W^{(j)} \sim N \left(\frac{\sum_{i=1}^n y_i w_i^{(j)}}{\sum_{i=1}^n w_i^{(j)}}, \frac{\sigma^{2(j)}}{\sum_{i=1}^n w_i^{(j)}} \right)$$

$$\frac{1}{\sigma^{2(j+1)}} | y, \mu^{(j+1)}, W^{(j)} \sim \text{Gamma} \left(\frac{n}{2}, \frac{1}{2} \sum_{i=1}^n (y_i - \mu^{(j+1)})^2 w_i^{(j)} \right)$$

$$w_i^{(j+1)} | y, \mu^{(j+1)}, \sigma^{2(j+1)}, w_1^{(j+1)}, \dots, w_{i-1}^{(j+1)}, w_{i+1}^{(j)}, \dots, w_n^{(j)} \sim \text{Exp} \left(\frac{1}{2} + \frac{1}{2\sigma^{2(j+1)}} (y_i - \mu^{(j+1)})^2 \right)$$

Listing 4: Algoritmo de Gibbs - Darwin (LearnBayes)


```

1 library(LearnBayes)
2
3 n=dim(darwin)[1]
4 y=data.frame(darwin)[,1]
5 mu=numeric()
6 sigma2=numeric()
7 W=matrix(0,1,n)
8
9 N=10000 #Tamaño de la simulación
10
11 #Valores iniciales
12 mu[1]=mean(y)
13 s2[1]=var(y)
14 W[1,]=rgamma(n,.5,.5)
15
16 #Algoritmo Gibbs
17 for(h in 1:N){
18   mu[h+1]=rnorm(1,sum(y*W[h,])/sum(W[h,]),sqrt(s2[h]/sum(W[h,])))
19   s2[h+1]=1/rgamma(1,0.5*n,0.5*sum((y-mu[h+1])^2*W[h,]))
20   w=c(rep(0,n))
21   for(j in 1:n){
22     w[j]=rexp(1,0.5+(0.5/s2[h+1])*(y[j]-mu[h+1])^2)
23   }
24   W=rbind(W,w)
25 }
```

Listing 5: Algoritmo de Gibbs, Gráfico de cadenas - Darwin (LearnBayes)

```

1 par(mfrow=c(2,1))
2 ts.plot(mu,col=2,xlab="iteración")
3 ts.plot(s2,col=2,xlab="iteración")
```



Comentarios:

Se observa una correcta convergencia por parte del algoritmo. Sin embargo los demás detalles lo veremos a continuación.

Programa WinBugs: Haremos uso del programa WinBugs para facilitar un estudio más sofisticado, para ello tendremos que tener en cuenta que necesitaremos la función verosimilitud y función a priori, respectivamente, de la siguiente forma:

$$\begin{aligned}\mathcal{L}(\mu, \sigma^2, W | y) &= p(y | \mu, \sigma^2, W) \sim N(\mu, \frac{\sigma^2}{W}) \\ p(\mu, \sigma^2, W) &= p(W | \mu, \sigma^2) p(\mu, \sigma^2) = \underbrace{p(W)}_{\sim \text{Gamma}(.5, .5)} \underbrace{p(\mu, \sigma^2)}_{\propto 1/\sigma^2} \\ &\quad \text{(no informativa)}\end{aligned}\tag{19}$$

Al tener una distribución a priori no informativa de μ y σ , dado que expresa información general pero no específica por cada variable, entonces consideramos lo siguiente:

$$\begin{aligned}\mu &\sim N(0, 100^2) \\ \sigma^2 &\sim \text{Gamma} - \text{Inversa}(0.01, 0.01)\end{aligned}$$

Listing 6: WinBugs, Algoritmo de Gibbs - Darwin (LearnBayes)

```

1 model{
2 # Posteriori
3 y[1]~dnorm(mu,tau1)
4 y[2]~dnorm(mu,tau2)
5 y[3]~dnorm(mu,tau3)
6 y[4]~dnorm(mu,tau4)
7 y[5]~dnorm(mu,tau5)
8 y[6]~dnorm(mu,tau6)
9 y[7]~dnorm(mu,tau7)
10 y[8]~dnorm(mu,tau8)
11 y[9]~dnorm(mu,tau9)
12 y[10]~dnorm(mu,tau10)
13 y[11]~dnorm(mu,tau11)
14 y[12]~dnorm(mu,tau12)
15 y[13]~dnorm(mu,tau13)
16 y[14]~dnorm(mu,tau14)
17 y[15]~dnorm(mu,tau15)
18
19 # Priori
20 # Por ser distribuciones no informativas
21 mu~dnorm(0,0.0001)
22 tau~dgamma(0.01,0.01)
23
24 s2<-1/tau
25 for(i in 1:n){
26 w[i]~dgamma(0.5,0.5)
27 }
28 tau1<-w[1]/s2
29 tau2<-w[2]/s2
30 tau3<-w[3]/s2
31 tau4<-w[4]/s2
32 tau5<-w[5]/s2
33 tau6<-w[6]/s2
34 tau7<-w[7]/s2
35 tau8<-w[8]/s2
36 tau9<-w[9]/s2
37 tau10<-w[10]/s2
38 tau11<-w[11]/s2
39 tau12<-w[12]/s2
40 tau13<-w[13]/s2
41 tau14<-w[14]/s2
42 tau15<-w[15]/s2
43 }
44
45 list(
46 n=15,
47 y=c(49,67,8,16,6,23,28,41,14,29,56,24,75,60,-48)
48 )

```

Obtenemos los siguientes resultados:




Figura 1: Gráfico de cadenas




Figura 2: Autocorrelación




Figura 3: Histogramas

node	mean	sd	MC error	5.0%	95.0%	start	sample
mu	28.45	7.342	0.1648	17.17	41.25	501	9500
s2	357.8	286.7	6.534	83.25	871.4	501	9500

Figura 4: Estadísticas Resumen

- El gráfico de cadenas nos informa una correcta convergencia del algoritmo, tal como se había observado usando R.
- El gráfico de autocorrelación es adecuado pues nos informa un grado de autocorrelación prácticamente nula.
- El gráfico de histogramas nos muestra una distribución, podría decirse normal para μ y log-normal para σ^2 .
- Se tiene las siguientes estimaciones de los parámetros

	μ	σ^2
Estimador Puntual	28.45	357.8
Intervalo de confianza 90 %	(17.17,41.21)	(83.25,871.4)

También podemos implementar un código en Listing 4, para determinar los estimadores puntuales de los parámetros y sus intervalos de confianza

Listing 7: Algoritmo de Gibbs, Intervalo de confianza 90 % - Darwin (LearnBayes)

```

1 mu=mu[1001:10000] #Eliminando las primeras 1000 iteraciones
2 s2=s2[1001:10000] #Eliminando las primeras 1000 iteraciones
3
4 # Estimadores puntuales
5
6 # Estimadores por Intervalo
7 quantile(mu, probs=c(0.05, 0.95))
8 quantile(s2, probs=c(0.05, 0.95))

```

	μ	σ^2
Estimador Puntual	25.95765	365.1222
Intervalo de confianza 90 %	(15.06591,38.25318)	(84.48391,931.79569)

□

f) Encuentre un intervalo de credibilidad al 90 % para una nueva observación.

Solución. En este caso tendremos que evaluar una nueva observación sobre la distribución de Cauchy con los parámetros puntuales estimados. Haremos uso de los resultados obtenidos por el algoritmo EM (Listing 1) algoritmo de Gibbs (usando Listing 4 y Listing 7).

Listing 8: Algoritmo de Gibbs, Intervalo de confianza 90 % - Darwin (LearnBayes)

```

1 # Para el algoritmo EM
2 quantile(rcauchy(N=1000,res[dim(res)[1],1],sqrt(res[dim(res)[1],2])),probs=c
  (0.05,0.95))
3
4 # Para el algoritmo de Gibbs
5 quantile(rcauchy(N=1000,mu.est,sqrt(s2.est)),probs=c(0.05,0.95))

```

Intervalo de confianza al 90 %	Nueva observación y
Algoritmo EM	(-71.87799,124.68244)
Algoritmo de Gibbs	(-89.5779,140.1819)

□